

1. Introdução:

Reat possui como objetivo minimizar o desperdício domiciliar de alimentos, utilizando dos recursos de chatbot para que o usuário possa visualizar possíveis receitas com base nos ingredientes disponíveis em sua residência, assim minimizando o desperdício de ingredientes pela utilização dos mesmos e a planejamento de suas receitas com base na quantidade de pessoas a serem atendidas a cada refeição.

O algoritmo para a criação do chatbot percorrerá uma série de testes com base em perguntas e testes de query da base de dados de receitas, para a melhor afinação com seu aprendizado de máquina e melhor se adequar às necessidades dos usuários.

Outro recurso utilizado foram algoritmos de lógica fuzzy para atender melhor a natureza das requisições dos usuários, das suas preferências e afins.

Além disso, serão utilizados algoritmos de hill climbing, modelos de regressão, que poderão por exemplo auxiliar com que o usuário mantenha seu estoque de alimentos frescos, minimizando o desperdício por depreciação de ingredientes.

2. Algoritmos de Otimização:

O algoritmo **Hill Climbing** pode ser aplicado de várias maneiras no Reat, principalmente quando se trata de otimizar sugestões de receitas ou melhorar a experiência de gerenciamento de estoque de alimentos.

Exemplo no Reat: Imagine que o usuário tenha ovos, queijo, tomates e espinafre na geladeira. O Hill Climbing pode começar com uma sugestão simples, como uma omelete. Em seguida, o algoritmo pode tentar alternativas como "omelete de espinafre e queijo" e avaliar qual solução utiliza mais ingredientes e atende melhor as preferências do usuário.

Lógica Fuzzy:

A **lógica fuzzy** se demonstra útil em cenários de incerteza, em que as variáveis não se restringem ao binário ou não são exatas. Tal se faz necessária para o tratamento dos cenários em que as preferências de um usuário, ou a quantidade de ingredientes, não são representadas com precisão.

Exemplo no Reat: Aqui, a lógica fuzzy pode ser utilizada para tratar preferências com relação aos alimentos dos usuários, do tipo "eu gosto de pratos picantes", ou "eu gosto de pratos leves", preferências essas de uma

representação imprecisa. Dado que um usuário diz que prefere um prato leve a lógica fuzzy entende como uma gama de pratos e não como um prato específico. A lógica fuzzy pode, ainda, ajudar a avaliar o que se pode considerar como a quantidade "suficiente" de ingredientes disponíveis para o preparo de uma receita, quando tais quantidades consideram variações na quantidade do produto ou na sua qualidade (frescor).

Modelos de ML e Classificação:

Os **Modelos de Regressão** podem prever a quantidade de certos ingredientes que um usuário necessita para uma receita em função do histórico de consumo ou das preferências passadas. Um exemplo no Reat: um modelo de regressão poderia prever a quantidade de arroz que um usuário costuma usar em uma receita para propor ações ajustadas.

Já o **Agrupamento (Clustering)** pode ser notado quando são usadas técnicas como K-means ou DBSCAN, pode-se agrupar os usuários com base nele mesmo ou segregar os ingredientes em categorias análogas (ex: legumes e carboidratos). Um exemplo no Reat: o clustering poderia ser útil para entender os padrões de uso de ingredientes e sugerir receitas que se harmonizem com aqueles ingredientes mais utilizados em determinado grupo de usuários.

A **Associação** está presente quando algoritmos de regras de associação têm como função descobrir combinações que apresentam maior frequência para serem utilizadas em receitas. Um exemplo no Reat: pode-se usar o algoritmo para identificar associados como tomate e manjeriço geralmente usados em conjunto e apresentar essas combinações aos usuários.

Visão Computacional:

Embora a **visão computacional** possa não ser a prioridade de um aplicativo como o Reat, pode ser utilizada em certas situações como aquelas que são descritas abaixo:

Reconhecimento de Imagens de Ingredientes: os usuários podem tirar fotos dos alimentos que eles têm na despensa para que o aplicativo utilize a visão computacional para reconhecer os itens e sugerir receitas a partir dessas imagens.

Exemplo do Reat: o aplicativo pode reconhecer a presença de frutas, vegetais, carnes ou outros itens em uma imagem e, a partir disso, sugerir receitas que combinam bem com esses ingredientes.

3. Dificuldades Gerais e Aprendizados

A coleta de dados apresentou dificuldades devido à necessidade de construir uma base sólida de ingredientes e suas combinações para gerar recomendações de receitas personalizadas. Além disso, a integração de uma API que permitisse buscar receitas de forma eficiente foi um processo demorado, exigindo testes e ajustes constantes até encontrar a melhor solução. O treinamento do chatbot também foi complicado, pois ele precisou aprender a associar combinações de ingredientes de maneira precisa, mesmo com entradas imprecisas dos usuários. Para isso, aprimoramos nossas habilidades em *Machine Learning*, além de estudos em *Python* e processamento de linguagem natural (PLN). A comunicação ativa no grupo foi essencial para superar os obstáculos técnicos e garantir a integração entre as diferentes partes do sistema.

Conclusão:

O projeto Reat busca reduzir o desperdício de alimentos doméstico, utilizando um chatbot inteligente que sugere receitas com base nos ingredientes disponíveis, preferências dos usuários e número de pessoas. O sistema aplica técnicas de IA e ML, como Hill Climbing, lógica fuzzy e modelos de regressão, para personalizar as sugestões e otimizar o uso dos ingredientes.

Resultados Principais:

- Redução de desperdício: O chatbot sugere receitas que aproveitam ao máximo os ingredientes disponíveis.
- Personalização: Adapta às receitas às preferências e quantidade de ingredientes do usuário.
- Otimização de estoque: Ajuda a gerenciar os ingredientes, minimizando desperdícios por depreciação.

Lições Aprendidas:

- A criação de uma base de dados robusta foi desafiadora, assim como o treinamento do chatbot para entender entradas imprecisas.
- A integração de diferentes algoritmos exigiu comunicação constante dentro do grupo.

Possíveis Melhorias:

- Aprendizado contínuo para melhorar as recomendações do chatbot com base no histórico do usuário.

- Visão computacional para identificar ingredientes a partir de imagens.
- Melhor gestão do frescor dos alimentos, sugerindo receitas antes que os ingredientes se estraguem.

Impacto Positivo da IA/ML:

As técnicas de IA e ML ajudaram a criar um sistema mais eficiente e personalizado, que otimiza o uso dos ingredientes e reduz o desperdício. O projeto contribuiu para o desenvolvimento do grupo, que ganhou experiência prática em IA, ML e colaboração técnica.

Por fim entendemos que o Reat não só ajudou a minimizar desperdícios, mas também proporcionou aprendizado significativo sobre como aplicar IA para resolver problemas cotidianos. O projeto tem grande potencial para evoluir, incorporando novas tecnologias como visão computacional e aprendizado contínuo.

Membros do Grupo PI:

- Nicolle Costa - **23025207**
- Lucas Silva - **20010551**
- Nicolas Bueno - **20010562**
- Vinicius Burato - **22024055**
- Rafael Silva - **23025211**
- Eduardo Fraga - **23024405**
- Rebeca Vieira - **23025215**
- Gabriel Berto- **23024654**